向量检索与混合检索实践

一、语义检索的基本流程

语义检索包含三步：把文档切成语义完整的块，用嵌入模型把每个块编码成向量，查询时把问题编码成同维度向量并计算相似度。常用的相似度是余弦相似度，它只关注方向不关注长度。中文场景建议选择在中文语料上训练过的嵌入模型，例如 bge 系列，并注意模型的最大输入长度，超长文本需要切块。

二、HNSW 索引

HNSW 是分层可导航小世界图。每个向量在每一层都有若干邻居，上层节点稀疏，用于快速跨越，下层节点稠密，用于精确搜索。查询从最高层的一个入口点开始，贪心地向距离更近的邻居移动，逐层下降，最后在底层做候选扩展。

HNSW 的质量由两个参数决定。M 控制每个节点的邻居数量，M 越大图越稠密，召回率越高，但内存和构建时间也越大。efConstruction 控制构建时的候选队列长度，影响图的质量。查询时的 ef 控制搜索队列长度，ef 越大召回越高、延迟越大。实践上先用默认参数建立基线，再针对召回率和延迟做网格搜索。

三、全文检索与 BM25

全文检索先把文本切分成词项，建立倒排索引，再用 BM25 等算法计算相关性。BM25 同时考虑词频、逆文档频率和文档长度归一化。它的优势是术语精确匹配：查询一个专有名词时，只要文档里出现过这个词，就能稳定召回，不受嵌入模型训练数据的影响。中文全文检索的关键是分词，词典分词和基于模型的分词各有取舍，领域术语需要自定义词典。

四、混合检索与 RRF 融合

向量检索擅长语义相近但用词不同的情况，全文检索擅长术语精确匹配，两者互补。混合检索同时执行两路召回，再融合排序。常用的融合算法是 RRF，即倒数排名融合：每个文档的得分等于它在各路结果中排名倒数的加权和，公式为 score = Σ 1 / (k + rank)，k 通常取 60。

RRF 只使用排名，不使用原始分数，因此不需要把余弦距离和 BM25 分数归一化到同一量纲，工程上非常稳健。如果需要更精细的控制，可以改成加权分数融合，但必须先做分数校准。

五、评测与常见问题

检索评测需要固定的查询集和相关性标注。常用指标包括 Recall@K、MRR 和 nDCG@K。Recall@K 衡量前 K 个结果覆盖了多少相关文档，MRR 关注第一个相关结果出现的位置，nDCG

还考虑排序位置和相关性等级。没有评测集时，至少准备二十条真实查询做人工判断。

常见问题包括：切块过大导致一个块包含多个主题，切块过小导致语义不完整；查询和文档使用不同的嵌入模型；索引构建后没有刷新导致检索不到新数据；只调一个通道的参数而忽略融合权重。排查时先看单通道效果，再看融合效果，逐层定位。